# №1 Теория информации

## План


- Введение в теорию информации
  - Мера информации
    - Математика
  - Информационная энтропия по Шеннону
    - Пример
      - Случай 1
      - Случай 2
      - Случай 3
    - Свойства информационной энтропии
    - Связь энтропии и компрессии
  - Избыточность данных
  - Классификация избыточности
    - По природе возникновения
      - Статистическая избыточность
      - Структурная избыточность
      - Психофизическая избыточность


## Введение в теорию информации

**Теория информации** занимается *двумя* ключевыми вопросами:

- Как *измерить* информацию?
- Как эффективно *передавать* и *хранить* информацию?
  - Каковы принципиальные пределы компрессии данных и скорости безошибочной передачи?

### Мера информации

**Информация** - в рамках ТИ, это мера мера уменьшения неопределённости.

> ⓘ **Пример**
>
> **Подброс монетки**
>
> ---
>
> Когда мы подбрасываем монетку, мы фактически определяем результат, что создаёт информацию

*Количество* информации *зависит от вероятности* события. Чем *менее вероятно* событие, тем *больше информации* несёт сообщение о его наступления.

### Математика

Математически для отдельного события $x_i$ с вероятностью $P(x_i)$ информация по Хартли-Шеннону измеряется как $I(x_i) = \log_2\left(\frac{1}{P(x_i)}\right) = -\log(P(x_i))$. При использовании логарифма по основанию 2, единица измерения - *бит*. 1 бит - это количество информации, которое устраняет неопределённость ровно в *два* раза.

## Информационная энтропия по Шеннону

**Энтропия источника** - это *среднее количество информации*, приходящееся на одно сообщение или символ. Мера средней неопределённости исхода. Формально для дискретного ансамбля $x$ с возможными исходами $x_1, x_2, \ldots, x_n$ и вероятностями $P(x_1), P(x_2), \ldots, P(x_n)$, энтропия Шеннона $H(x_i)$ определяется как математическое ожидание информации $H(x_i) = -\Sigma_i^n P_i \cdot \log_2(P_i)$. Это мера непредсказуемости источника.

### Пример

Рассмотрим двоичный источник

### Случай 1

$P(0) = \pm 1$, то $H(A) = -(0,5 \cdot \log(0,5) + 0,5 \cdot \log_2(0,5)) = 1$. Максимальная неопределённость.

### Случай 2

$P(0) = 0,99,\ P(1) = 0,01$, то $H(B) = 0,0808$

### Случай 3

$P(0) = 1,\ P(1) = 0$, то $H(C) = 0$

## Свойства информационной энтропии

1. Энтропия всегда *не отрицательна*.
2. Энтропия равна *нулю*, когда события полностью *определенно*.
3. *Максимум энтропии* достигается при равномерном распределении вероятностей между событиями. $H_{max} = \log_2(n)$, где $n$ -количество возможных исходов.
4. Энтропия *аддитивна* для независимых источниках. То есть неопределённость двух независимых монеток в два раза больше чем одной.

## Связь энтропии и компрессии

Энтропия позволяет дать ответ на вопрос до какого предела можно выполнить компрессию данных без потерь.

**Теорема Шеннона**

Сообщение порождаемое источником с энтропией $H_x$ бит на символ *невозможно закодировать* со средней длинной кода *меньше* чем $H_x$ бит на символ. При этом существуют коды позволяющие достичь средней длинны сколь угодно близкой к $H_x$. Таким образом энтропия устанавливает предел сжатия без потерь.

## Избыточность данных

**Избыточность** - это та часть данных которая может быть устранена без потери информации. Иными словами наличние в данных предсказуемой повторяющейся информации, превышающая минимальный необходимый объём для их исполнения.

Формально для источника $x$ с энтропией $H_x$ и алфавитом размера $n$ стандартная, *относительная* избыточность $R$ определяется как $R = 1 - \frac{H_x}{H_{max}}$. Так же есть *абсолютная* избыточность $D = H_{max} - H_x$. Если $H_x$ меньше $H_{max}$, то источник обладает избыточностью. Чем ниже энтропия по сравнению с максимумом, тем выше избыточность.

## Классификация избыточности

### По природе возникновения

#### Статистическая избыточность

*Статистическая* или *вероятностная* избыточность - *частые символы* кодируются такими же длинными кодами, что и редкие. Устраняются методами энтропийного кодирования.

#### Структурная избыточность

*Структурная* избыточность возникает из за *зависимости* между соседними символами, блоками символов или более дальними символами. Иными словами последовательности символов *не* являются *случайными* и имеют некоторые *закономерности*. Устраняются с помощью применения следующих подходов:

- *Контекстное моделирование* - предсказание следующего символа с помощью истории и кодирование лишь разницу между ними.
- *Словарные методы* - замена повторяющихся структур ссылками на их предыдущие вхождения.

- *Кодирование с прогнозом (дельта кодирование)* - кодирование данных между текущими заданными значениями.
  По сути данный тип избыточности устраняется переходом от энтропии нулевого порядка к условной энтропии.
  Частный случай - комбинаторная избыточность.

### Психофизическая избыточность

*Психофизическая* избыточность - это передача информации, которую человек не может принципиально воспринять в связи с физическими ограничениями. Устраняется с помощью удаления лишней информации.